

Beginner Overview Rev.A — webRagSys 初心者向け解説

このドキュメントは、webRagSys を初めて読むPython中級者・RAG初心者のために書かれています。Pythonの基本構文ではなく、FastAPIとLangChainによるRAGの仕組みに焦点を当てます。

Rev.A は初版の別名保存版です。文体を「です」調に統一し、略語の展開、SQLite正規運用の明記、Docker対象外の注記、簡略図の注記を追加しています。原ファイルは変更していません。

1. プロジェクト全体構造と役割

1.1 このプロジェクトは何をするのか

webRagSys は、社内文書を登録し、その文書を根拠にAIが回答するWeb APIシステムです。

- 文書CRUD（Create登録／Read読出／Update更新／Delete削除）：タイトルと本文を登録・一覧・詳細・更新・削除します
- RAG化（Retrieval-Augmented Generation = 検索拡張生成）：文書を分割し、Embedding化してVector Databaseへ保存します
- AIチャット：質問をEmbedding化し、類似文書を検索してLLM（Large Language Model = 大規模言語モデル）が回答します
- 既定は偽実装：EmbeddingもLLMもFakeを使い、課金なしで学習できます

たとえるなら、文書管理は書庫係、RAGは索引係、LLMは回答係です。

1.2 フォルダ構成

webRagSys/	
├── AGENTS.md	← 作業規約（必読）
├── README.md	← 使い方入門書
├── config.py	← 設定集約（DB、RAG、LLM切替）
├── requirements.txt	← 依存一覧
├── Dockerfile	← APIイメージ定義（構成見本、起動対象外）
├── docker-compose.yml	← API + PostgreSQL + pgvector構成（構成見本、起動対象外）
├── .env.example	← 公開用設定見本（実キーは書かない）
├── src/api/main.py	← 起動点（create_app、ルータ登録）
├── src/api/routers/	← documents.py（CRUD）、chat.py（質問応答）
├── src/schemas/	← Pydantic入出力定義
├── src/db/	← database.py（接続）、models.py（2テーブル）
├── src/rag/	← chunker、embeddings、vectorstore、chain
├── src/llm/	← provider.py（切替）、fake_provider.py（偽回答）
├── tests/	← test_documents.py、test_chat.py、conftest.py
├── docs/	← 本書、handover.md、assets/（図PNG）
├── .venv/	← 仮想環境（Git除外、各自作成）
└── diagrams/	← 図の元データ（Mermaid形式）

注意点：Dockerfileとdocker-compose.ymlは構成見本であり、storage制約のため起動検証の対象外です。正規の動作確認はローカル起動（uvicorn + SQLite）で行います。

1.3 各フォルダの担当

フォルダ	役割	たとえば...
------	----	---------


src/api/	HTTP受付と振分	受付窓口
src/schemas/	入出力の検品	受付票の雛形
src/db/	保存と読出	書庫
src/rag/	分割・検索・回答組立	索引係と下書き係
src/llm/	文章生成	回答係
tests/	品質保証	検品係
docs/	設計書・説明書	マニュアル

1.4 主要ファイルの役割

ファイル	担当	重要なポイント
config.py	設定集約	USE_FAKE=true既定、chunk_size=500、top_k=3
src/api/main.py	app生成	create_app()でルータ登録する
src/api/routers/documents.py	CRUD	登録・更新時にchunks再生成する（57、104行目）
src/db/models.py	2テーブル	documentsとdocument_chunks、Postgres時はVector型
src/rag/chunker.py	分割	LangChain優先、なければ単純分割に退避する
src/rag/embeddings.py	ベクトル化	Fake既定、本番のみOpenAI通信する
src/rag/vectorstore.py	保存検索	置換保存、コサイン類似検索する
src/rag/chain.py	回答手順	検索→整形→生成の順序だけを決める
src/llm/provider.py	切替	Fakeか本番かを1か所で決める

2. モジュール間の依存関係

2.1 依存関係の全体像



▶ 図の元データ (Mermaid)

2.2 依存の方向性

webRagSysでは「API → RAG → DB／LLM」の一方通行で依存します。

```

src/api/main.py (create_app)
├── src/api/routers/documents.py (CRUDを依頼)
│   ├── src/db/models.py (保存)
│   └── src/rag/chunker.py+vectorstore.py (RAG化)
├── src/api/routers/chat.py (質問応答を依頼)
│   └── src/rag/chain.py (answer_question)
│       ├── src/rag/vectorstore.py (類似検索)
│       └── src/llm/provider.py (文章生成)
└── src/db/database.py (DB初期化)

```

「一方通行」が重要な理由： `src/db/` が `src/api/` を参照することはありません。これによってDB実装をPostgreSQLから他DBへ変えてもAPI層に影響が出ません。

2.3 `import` のしくみ — なぜ遅延importするのか

```

# src/db/database.py : init_db内で遅延importする
from src.db import models # テーブル登録のため

```

読み方のコツ：通常の `import` はファイル先頭に書きますが、循環参照を避けたい場合だけ関数内で書きます。ここでは `database.py` と `models.py` が互いを参照するため、実行直前に読み込む方式にしています。

2.4 呼び出しの流れ（具体例）

```

# documents.py:57 (登録時にRAG化する)
vectorstore.save_chunks(db, doc.id, chunker.split_text(doc.content))


# chain.py (質問時の流れ)
hits = vectorstore.search(db, question) # 類似検索
context = "\n".join(h.content for h in hits) # 類似文を結合
answer = generate_answer(question, context) # LLM生成


```

3. データの流れ（3つのフェーズ）

webRagSysのデータは「登録する → RAG化する → 質問に答える」の3段階で流れます。

3.1 全体フロー





▶ 図の元データ（Mermaid）

注意点：上図は初学者向けの簡略図です。GET（一覧・詳細）とDELETEの分岐を省略しています。完全な分岐は `diagrams/01_flowchart_RevA.md` で確認できます。


3.2 フェーズ1：文書登録（外部 → DB）

CRUDの5APIが `documents` テーブルを操作します。

API	処理	RAG連動
POST /documents	挿入	chunks生成する
PUT /documents/id	更新	chunks置換する
DELETE /documents/id	削除	chunks削除する
GET /documents	一覧	連動なし
GET /documents/id	詳細	連動なし

置換保存の理由（`vectorstore.py:55`）：更新時に古いベクトルが残ると誤検索の原因になるため、一度全削除してから挿入し直します。

3.3 フェーズ2：RAG化（文書 → ベクトル）




► 図の元データ（Mermaid）

RAG初心者向けの要点：

- **チャンク**：長文を500文字単位に切った断片です。検索精度とLLM入力長の調整役です。
- **Embedding**：文章を数値ベクトル化する処理です。意味の近さが数値の近さになります。
- **SQL検索との違い**：SQLは完全一致探し、ベクトル検索は意味の近さ探しです。「休暇は何日」と「年次休暇は10日」は文字は違いますが意味が近いので検索できます。

3.4 フェーズ3：質問応答（質問 → 回答）



► 図の元データ（Mermaid）

データベースのテーブル構成：

documents（文書本体）

|

- └── document_chunks (RAG用断片)
 - └── document_id で紐づく
 - └── chunk_index、content、embeddingを保持

4. 中級者がつまずきやすいポイント

4.1 FastAPI編

FastAPIの `Depends(get_db)` (`documents.py:62`)

```
def list_documents(db: Session = Depends(get_db)) -> list[Document]:
```

何をしているのか：「このAPIを呼ぶ前に `get_db()` を実行し、その結果を `db` 引数に入れてほしい」という宣言です。

なぜ必要なのか：DB接続の開閉を各APIに書くと重複します。`Depends` に任せると、成功時はセッション提供、終了時は自動 `close` になります。テスト時は `dependency_overrides` で偽DBに差し替えられます (`tests/conftest.py`)。

間違えやすいポイント：`Depends(get_db())` のように括弧付きで書くと実行結果が固定され、リクエストごとに新規接続されません。括弧なしが正解です。

Pydanticの `from_attributes` (`schemas/document.py`)

```
class DocumentOut(BaseModel):  
    model_config = {"from_attributes": True}
```

何をしているのか：SQLAlchemyの行オブジェクトからPydantic応答への変換を許可します。

なぜ必要なのか：`Document` 行を `DocumentOut` に変換する際、辞書でなく属性アクセス (`doc.title`) で読む必要があるためです。これがないと一覧・詳細APIの返却時に変換エラーになります。

`on_event("startup")` の役割 (`main.py`)

起動時に `init_db()` を実行し、テーブルとpgvector拡張を作成します。テスト時はDB未起動でもimportできるよう、失敗時は警告記録のみにしています。

注意点：`on_event` は新版FastAPIで非推奨表示になりますが動作します。将来は `lifespan` 方式への置換対象です。

4.2 LangChain編

TextSplitter — なぜ分割するのか (`chunker.py`)

```
splitter = RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=50)
```

何をしているのか：長文を500文字単位に切り、50文字だけ重ねます。

なぜ必要なのか：区切れ目で文意が切断されるのを防ぐためです。重なり部分が前後関係を保持します。本実装ではLangChainがあればそれを使い、なければ単純分割に退避します。

間違えやすいポイント：`chunk_size` を大きくすれば精度が上がるわけではありません。大きすぎるとLLM入力に関連の薄い文章で埋まります。`config.py` の500と3件は学習用の出発点です。

Embeddings — Fakeと本番の違い (embeddings.py:54)

```
if settings.use_fake or not settings.openai_api_key:
    return [_fake_vector(t) for t in texts]
```

何をしているのか：既定は課金なしFake、本番のみOpenAI通信です。

なぜ必要なのか：学習中にAPI課金が発生しないようにするためです。Fakeは文字コード合計から決定的ベクトルを作るため、再実行しても同じ結果になります。

間違えやすいポイント：Fakeは意味を理解していません。文字の並びが近い文書が類似と判定されます。本番Embeddingに替えると意味検索になりますが、配線自体は同じです。

RetrieverとChain — なぜ薄い層なのか (chain.py)

```
hits = vectorstore.search(db, question)
context = "\n".join(h.content for h in hits)
answer = generate_answer(question, context)
```

何をしているのか：検索と生成の順序だけを決めています。

なぜ必要なのか：LangChainの本格Chain（LCEL = LangChain Expression Language等）に置き換える際、呼出側（ chat.py ）を変更せずに済むためです。現段階では見通し優先の最小実装です。

4.3 DB／RAG編

pgvector拡張 — なぜ必要なのか (database.py)

PostgreSQLでベクトル列を使うには CREATE EXTENSION IF NOT EXISTS vector が必要です。ローカル正規運用のSQLiteではJSON列で代替します（ models.py ）。件数が少ない学習段階ではPython側のコサイン計算で十分です。

コサイン類似度 — 何を計算しているのか (vectorstore.py:28)

```
dot / (na * nb)
```

何をしているのか：2ベクトルの向きの近さを0～1で数値化しています。1に近いほど類似です。

なぜ必要なのか：ベクトル検索の核心だからです。質問ベクトルと全チャンクの類似度を計算し、上位3件（ top_k ）だけをLLMへ渡します。

.env と .env.example の違い

ファイル	役割	Git管理
.env	実設定値（APIキー含む）	除外する
.env.example	公開用見本（空欄）	含める

間違えやすいポイント：.env をcommitするとAPIキーが公開されます。config.py は .env を読みますが、キーなしでもFake動作するため学習に支障はありません。

5. 操作と内部の対応（/docs利用者向け）


本章は操作画面（ /docs ）の表示と内部処理の対応を1か所にまとめたものです。たとえるなら、5.1は案内板の読み方、5.2は券売機の番号案内、5.3は厨房の手順書です。

5.1 /docsの4分類の読み方

分類	所属	役割
default	GET /health	生存確認です。タグなしのため未分類置場に表示されます
documents	文書CRUD5件	登録・一覧・詳細・更新・削除です
chat	POST /chat	質問応答です
schemas	型定義	入出力雛形の参照用です。実行対象ではありません

注意点： / は未定義のため404が正常です。確認は /health 、 /docs 、 /documents の3件で行います。

5.2 群別Code対応表



▶ 図の元データ（Mermaid）

default群 GET /health

Code	意味	対応
200 body ok	サーバ生存確認です	以降操作可です
接続自体不可	サーバ未起動か別ポートです	起動確認に戻ります

default群にDELETEは存在しません。 /docs に表示なしが正常です。

documents群

操作	Code	意味	対応
GET /documents	200 []	登録ゼロで正常です	異常ではありません


GET /documents	200 件数あり	登録済み一覧です	body確認です
GET /documents/id	200	詳細表示です	body確認です
GET /documents/id	404	存在しないIDです	番号確認です
GET /documents/id	422	ID欄に数字以外です	数字に修正します
POST /documents	201	登録成功です	返却idを控えます
POST /documents	422	titleかcontentが空です	両方記載し再送します
PUT /documents/id	200	更新成功です	関連検索情報も置換済みです
PUT /documents/id	404	対象なしです	id確認です
PUT /documents/id	422	入力規則違反です	空欄修正です
DELETE /documents/id	204	削除成功です	bodyなしが正常です
DELETE /documents/id	404	対象なしです	id確認です

chat群 POST /chat

Code	意味	対応
200 answerあり source_idsあり	会話成立です	answer欄が回答、source_idsが根拠番号です
200 answerあり source_ids空	根拠なし回答です	先に文書登録します
422	question空です	1文字以上記入し再送します
500	内部障害です	再起動し再送します。継続時は記録します

会話成立条件：先にPOST /documentsで登録し、次にPOST /chatで質問します。逆順では根拠空になります。

5.3 内部trace（画面の裏側）



▶ 図の元データ（Mermaid）

- 受付はFastAPIが行います。接続は要求ごとに開閉します。
- 検査で空欄と型を確認します。違反は422で返します。
- 一覧と詳細は書庫直読みでRAG不使用です。
- 登録と更新は保存後に索引を作り直します。削除は索引削除が先です。
- 質問は類似検索の上位3件だけを回答生成に渡します。

5.4 回答と異常の見分け方

- 成功形は `answer` と `source_ids` を持ちます。Code 200で返ります。
- 失敗形は `detail` と `msg` を持ちます。Code 422等で返ります。
- `/docs` は両雛形を常時表示します。実結果のCodeで判別します。

付録：学習の順番

STEP 1: README.md	→ 目的と使い方を理解
STEP 2: config.py	→ 設定値を把握
STEP 3: src/db/models.py	→ 2テーブルを把握
STEP 4: src/api/routers/documents.py	→ CRUDを読む
STEP 5: src/rag/chunker.py	→ 分割を読む
STEP 6: src/rag/embeddings.py	→ Fakeと本番の切替を読む
STEP 7: src/rag/vectorstore.py	→ 保存と検索を読む
STEP 8: src/llm/provider.py	→ 切替を読む
STEP 9: src/rag/chain.py	→ 回答手順を読む
STEP 10: src/api/routers/chat.py	→ 質問応答を読む
STEP 11: tests/	→ 検証内容を読む
STEP 12: diagrams/	→ 図で全体を復習
STEP 13: 本書5章	→ 操作と内部の対応を復習

このドキュメントは `README.md`、`AGENTS.md`、`config.py` および `src/`、`tests/` の実コードを参照して作成されています。初版 `beginner_overview.md` の別名保存版（Rev.A）です。