# Beginner Overview Rev.B — webRagSys 初心者向け解説

このドキュメントは、`webRagSys` を初めて読むPython中級者・RAG初心者のために書かれています。Pythonの基本構文ではなく、FastAPIとLangChainによるRAGの仕組みに焦点を当てます。

Rev.B は Rev.A の継承版です。Rev.A の内容に、技術スタック一覧、文書種別、遅延importの具体的影響、Depends括弧付きの理由、CREATE EXTENSIONの詳細、コサイン類似度のユーザー視点の6件を追加しています。Rev.A は変更していません。

---

## 1. プロジェクト全体構造と役割

### 1.1 このプロジェクトは何をするのか

**webRagSys** は、社内文書を登録し、その文書を根拠にAIが回答するWeb APIシステムです。

- 文書CRUD（Create登録／Read読出／Update更新／Delete削除）：タイトルと本文を登録・一覧・詳細・更新・削除します
- RAG化（Retrieval-Augmented Generation＝検索拡張生成）：文書を分割し、Embedding化してVector Databaseへ保存します
- AIチャット：質問をEmbedding化し、類似文書を検索してLLM（Large Language Model＝大規模言語モデル）が回答します
- 既定は偽実装：EmbeddingもLLMもFakeを使い、課金なしで学習できます

たとえるなら、文書管理は書庫係、RAGは索引係、LLMは回答係です。

### 1.2 フォルダ構成

```
webRagSys/
 ├── AGENTS.md              ← 作業規約（必読）
 ├── README.md              ← 使い方入門書
 ├── config.py              ← 設定集約（DB、RAG、LLM切替）
 ├── requirements.txt       ← 依存一覧
 ├── Dockerfile             ← APIイメージ定義（構成見本、起動対象外）
 ├── docker-compose.yml     ← API＋PostgreSQL＋pgvector構成（構成見本、起動対象外）
 ├── .env.example           ← 公開用設定見本（実キーは書かない）
 ├── src/api/main.py        ← 起動点（create_app、ルータ登録）
 ├── src/api/routers/       ← documents.py（CRUD）、chat.py（質問応答）
 ├── src/schemas/           ← Pydantic入出力定義
 ├── src/db/                ← database.py（接続）、models.py（2テーブル）
 ├── src/rag/               ← chunker、embeddings、vectorstore、chain
 ├── src/llm/               ← provider.py（切替）、fake_provider.py（偽回答）
 ├── tests/                 ← test_documents.py、test_chat.py、conftest.py
 ├── docs/                  ← 本書、handover.md、assets/（図PNG）
 ├── .venv/                 ← 仮想環境（Git除外、各自作成）
 └── diagrams/              ← 図の元データ（Mermaid形式）
```

**注意点**：Dockerfileとdocker-compose.ymlは構成見本であり、storage制約のため起動検証の対象外です。正規の動作確認はローカル起動（uvicorn＋SQLite）で行います。

### 1.3 各フォルダの担当

| フォルダ | 役割 | たとえると… |
|---|---|---|

| | | |
|---|---|---|
| src/api/ | HTTP受付と振分 | 受付窓口 |
| src/schemas/ | 入出力の検品 | 受付票の雛形 |
| src/db/ | 保存と読出 | 書庫 |
| src/rag/ | 分割・検索・回答組立 | 索引係と下書き係 |
| src/llm/ | 文章生成 | 回答係 |
| tests/ | 品質保証 | 検品係 |
| docs/ | 設計書・説明書 | マニュアル |

### 1.4 主要ファイルの役割

| ファイル | 担当 | 重要なポイント |
|---|---|---|
| **config.py** | 設定集約 | USE_FAKE=true既定、chunk_size=500、top_k=3 |
| **src/api/main.py** | app生成 | create_app()でルータ登録する |
| **src/api/routers/documents.py** | CRUD | 登録・更新時にchunks再生成する（57、104行目） |
| **src/db/models.py** | 2テーブル | documentsとdocument_chunks、Postgres時はVector型 |
| **src/rag/chunker.py** | 分割 | LangChain優先、なければ単純分割に退避する |
| **src/rag/embeddings.py** | ベクトル化 | Fake既定、本番のみOpenAI通信する |
| **src/rag/vectorstore.py** | 保存検索 | 置換保存、コサイン類似検索する |
| **src/rag/chain.py** | 回答手順 | 検索→整形→生成の順序だけを決める |
| **src/llm/provider.py** | 切替 | Fakeか本番かを1か所で決めます |

### 1.5 技術スタック一覧と使い方概要

`requirements.txt` 、`docker-compose.yml` 、`config.py` の実測に基づきます。

| 技術 | 版・実態 | 使い方概要 | 主な使用箇所 |
|---|---|---|---|
| Python | 3.11実測、3.10互換です | 全実装の言語です | 全体です |
| FastAPI | 0.110以上です | HTTP受付と振分、入出力検証です | src/api/main.py、src/api/routers/です |
| uvicorn | 0.29以上です | 起動サーバです | uvicorn src.api.main:app --reloadです |
| SQLAlchemy | 2.0以上です | 文書とチャンクの保存読出です | src/db/database.py、src/db/models.pyです |

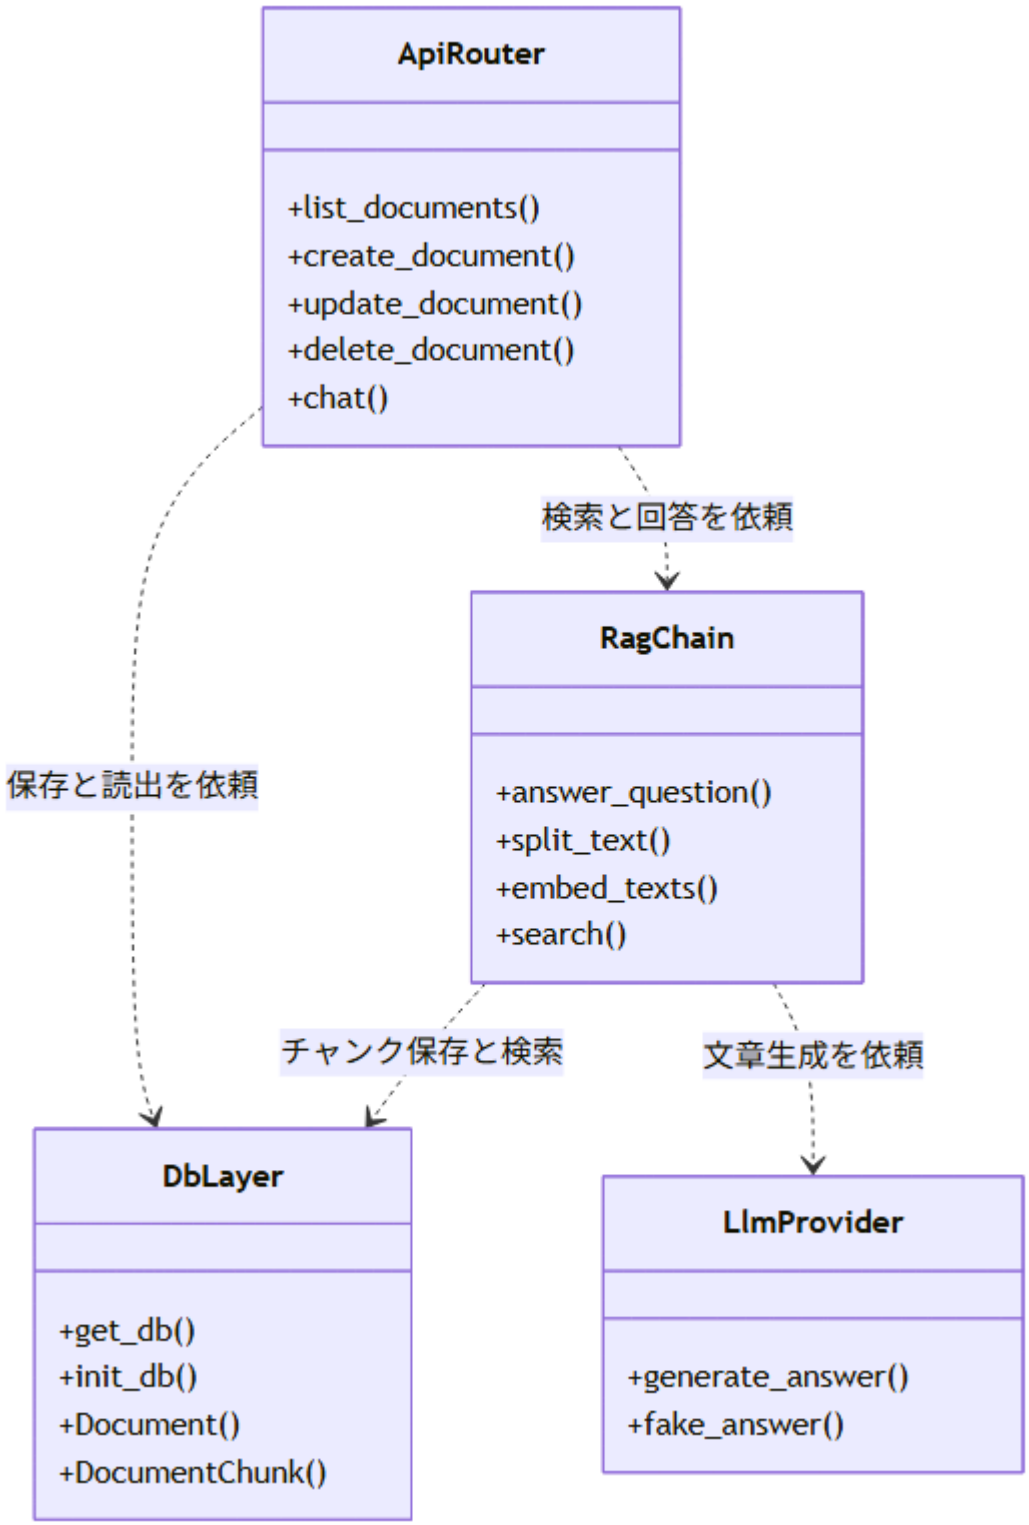
| | | | |
|---|---|---|---|
| psycopg2-binary | 2.9以上です | PostgreSQL接続駆動です | src/db/database.py:_create_engineです |
| pgvector | 0.3以上、DBはpgvector/pg16です | ベクトル列型の提供です | src/db/models.py:_embedding_columnです |
| Pydantic / pydantic-settings / python-dotenv | 2.6以上 / 2.2以上 / 1.0以上です | 入出力雛形と設定集約です | src/schemas/、config.pyです |
| LangChain一式 | langchain、langchain-community、langchain-openai、langchain-postgres、langchain_text_splittersです | 分割とEmbeddingと生成の枠組みです | src/rag/chunker.py、src/rag/embeddings.py、src/llm/provider.pyです |
| SQLite | 標準組込です | PostgreSQL不在時の退避先です | src/db/database.py、src/db/models.py:JSON代替です |
| pytest / httpx | 8.0以上 / 0.27以上です | 偽実装による無課金試験です | tests/です |
| ruff | 0.4以上です | 検査です | src、tests、config.pyです |
| Docker / docker-compose | 構成見本、起動検証対象外です | APIとPostgreSQL構成の見本です | Dockerfile、docker-compose.ymlです |

正規の動作確認はローカル起動（uvicorn＋SQLite）で行います。

---

## 2. モジュール間の依存関係

### 2.1 依存関係の全体像




▶ 図の元データ（Mermaid）

### 2.2 依存の方向性

webRagSysでは「**API → RAG → DB／LLM**」の一方通行で依存します。

```
src/api/main.py（create_app）
  ├── src/api/routers/documents.py（CRUDを依頼）
  │     ├── src/db/models.py（保存）
  │     └── src/rag/chunker.py＋vectorstore.py（RAG化）
  ├── src/api/routers/chat.py（質問応答を依頼）
  │     └── src/rag/chain.py（answer_question）
  │           ├── src/rag/vectorstore.py（類似検索）
  │           └── src/llm/provider.py（文章生成）
  └── src/db/database.py（DB初期化）
```

**「一方通行」が重要な理由：** `src/db/` が `src/api/` を参照することはありません。これによってDB実装をPostgreSQLから他DBへ変えてもAPI層に影響が出ません。

### 2.3 `import` のしくみ — なぜ遅延importするのか

```python
# src/db/database.py：init_db内で遅延importする
from src.db import models  # テーブル登録のため
```

**読み方のコツ：** 通常の `import` はファイル先頭に書きますが、循環参照を避けたい場合だけ関数内で書きます。ここでは `database.py` と `models.py` が互いを参照するため、実行直前に読み込む方式にしています。

**行わなければ何が起きるのか：** `src/db/models.py:18` は `from src.db.database import Base, engine` で `Base` を要求します。`database.py` の先頭で `from src.db import models` と書くと、`Base = declarative_base()` の定義前に `models.py` の読込が始まり、`ImportError: cannot import name 'Base' from partially initialized module` で起動しません。`init_db` 内の遅延読込は `Base` と `engine` の生成後に `models.py` を読むため、この衝突を避けられます。同様に `embeddings.py:57` と `llm/provider.py:38` の `langchain_openai` 遅延読込と `models.py:34` の `Vector` 遅延読込は、未導入環境でも先頭読込時の `ImportError` を出さずFake動作とSQLite退避を可能にします。

### 2.4 呼び出しの流れ（具体例）

```python
# documents.py:57（登録時にRAG化する）
vectorstore.save_chunks(db, doc.id, chunker.split_text(doc.content))

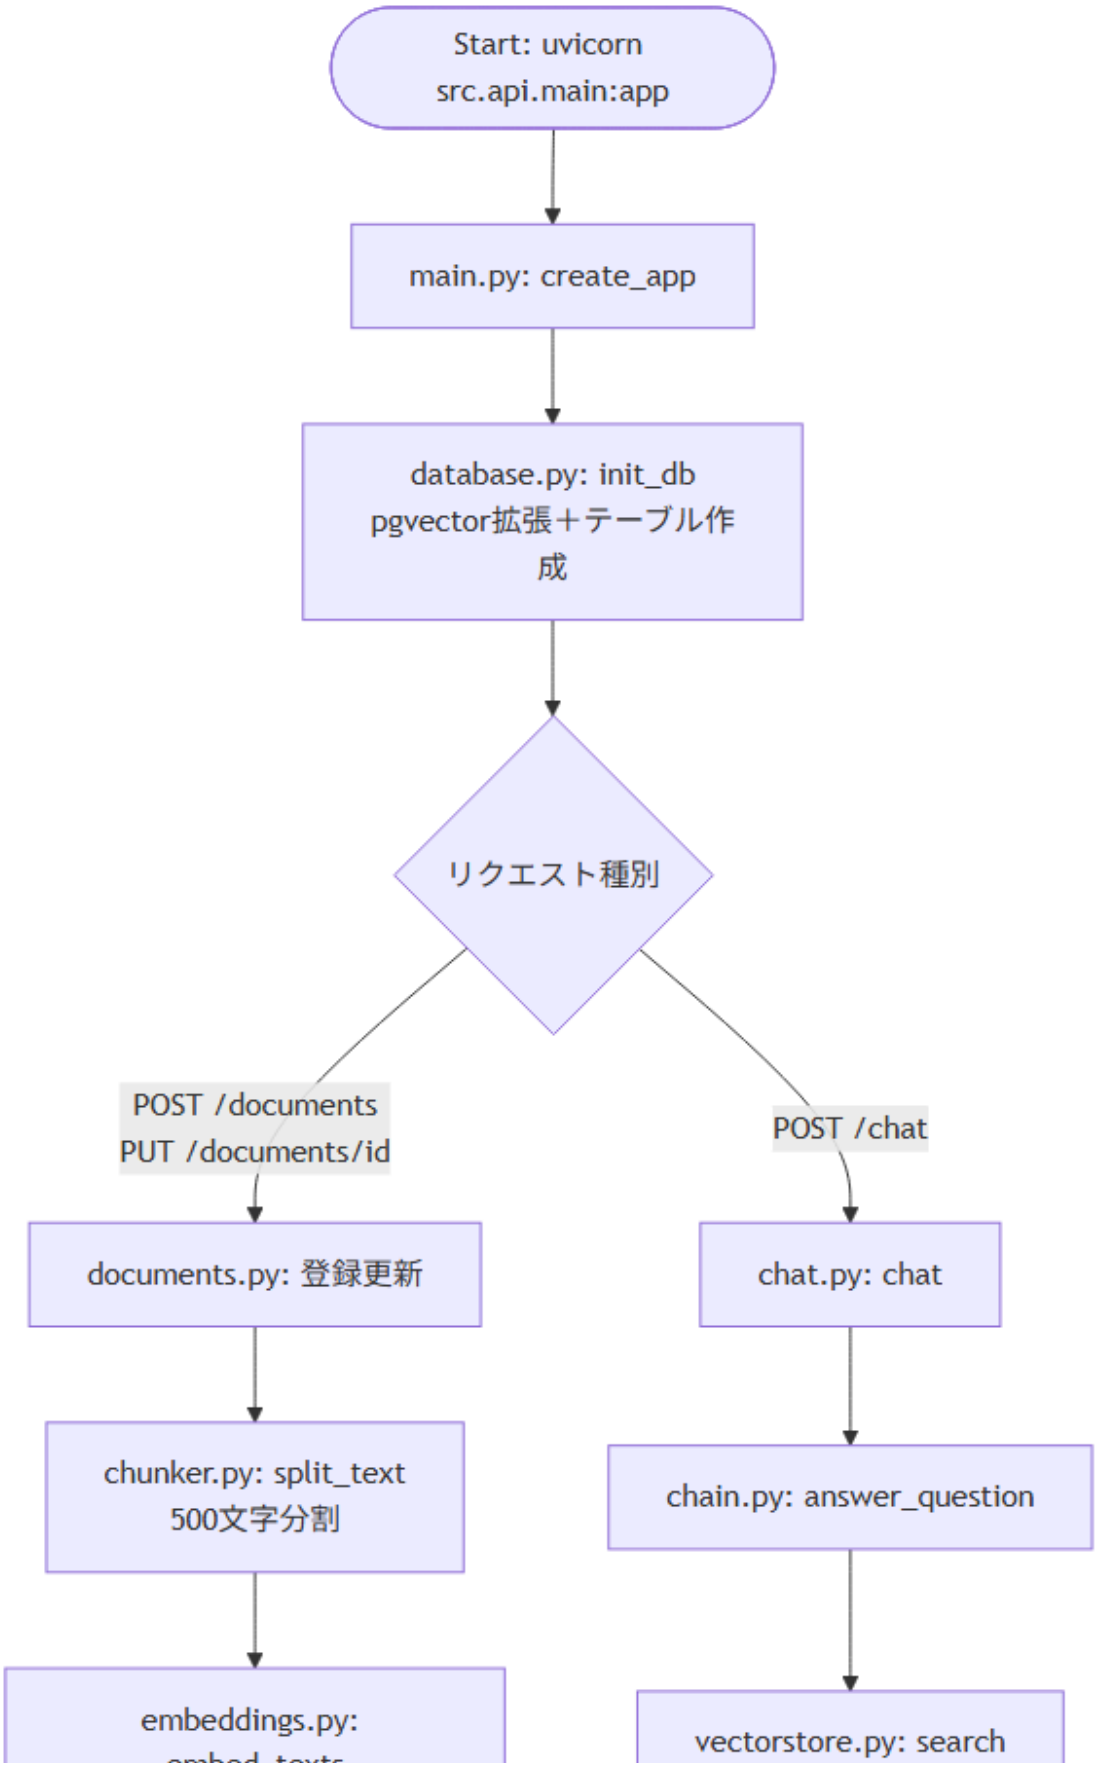
# chain.py（質問時の流れ）
hits = vectorstore.search(db, question)  # 類似検索
context = "¥n".join(h.content for h in hits)  # 類似文を結合
answer = generate_answer(question, context)  # LLM生成
```

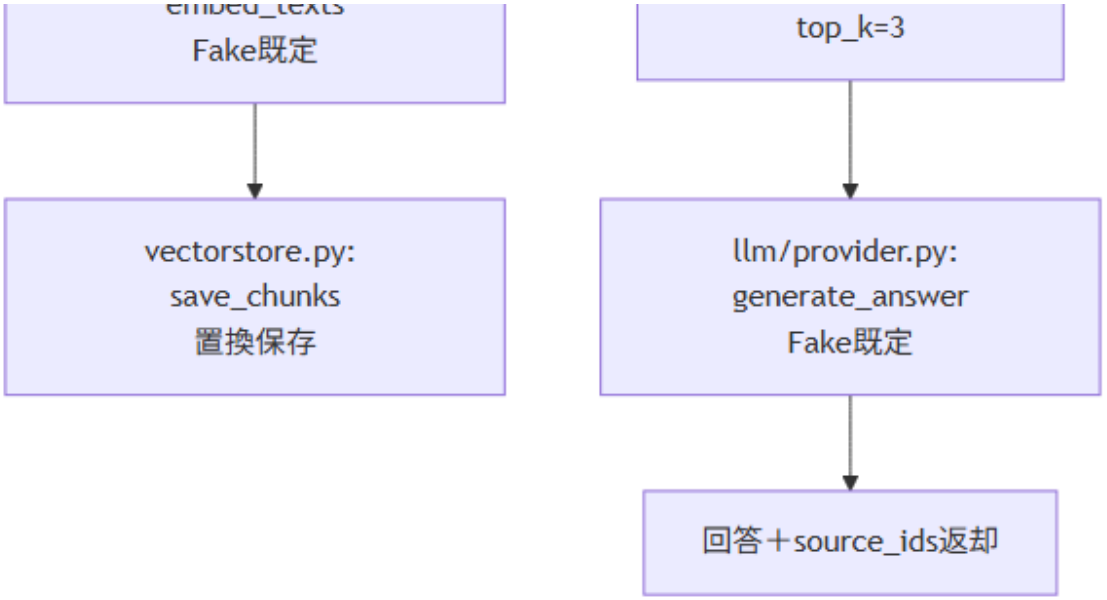
---

## 3. データの流れ（3つのフェーズ）

webRagSysのデータは「**登録する → RAG化する → 質問に答える**」の3段階で流れます。

### 3.1 全体フロー


Start: uvicorn
src.api.main:app
main.py: create_app
database.py: init_db
pgvector拡張＋テーブル作成
リクエスト種別
POST /documents
PUT /documents/id
POST /chat
documents.py: 登録更新
chat.py: chat
chunker.py: split_text
500文字分割
chain.py: answer_question
embeddings.py:
vectorstore.py: search




▶ 図の元データ（Mermaid）

**注意点**：上図は初学者向けの簡略図です。GET（一覧・詳細）とDELETEの分岐を省略しています。完全な分岐は `diagrams/01_flowchart_RevA.md` で確認できます。

### 3.2 フェーズ1：文書登録（外部 → DB）

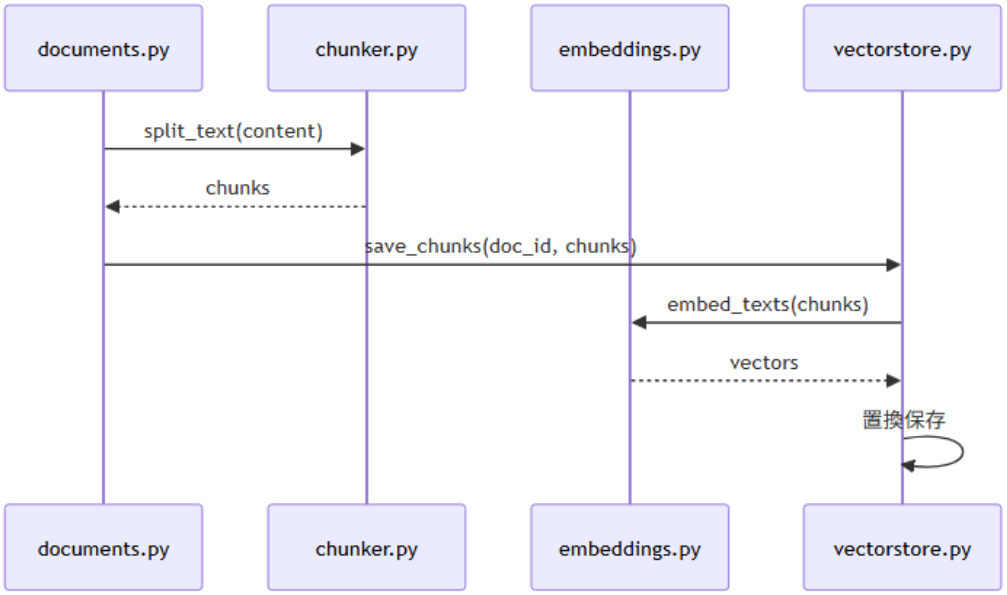
CRUDの5APIが `documents` テーブルを操作します。

| API | 処理 | RAG連動 |
|---|---|---|
| POST /documents | 挿入 | chunks生成する |
| PUT /documents/id | 更新 | chunks置換する |
| DELETE /documents/id | 削除 | chunks削除する |
| GET /documents | 一覧 | 連動なし |
| GET /documents/id | 詳細 | 連動なし |

**置換保存の理由**（ `vectorstore.py:55` ）：更新時に古いベクトルが残ると誤検索の原因になるため、一度全削除してから挿入し直します。

**扱える文書の種別**：現状はテキストのみです。`src/schemas/document.py` で `title` は1文字以上200文字以下、`content` は1文字以上と定め、`src/db/models.py` で `content` を `Text` 列に保存します。入力経路は `POST /documents` のJSON本文だけであり、PDFやWordや画像や音声の直接受付はありません。ファイル添付欄は `/docs` に表示されないのが正常です。PDFやWord対応は `src/rag/chunker.py` の今後の拡張対象です。

### 3.3 フェーズ2：RAG化（文書 → ベクトル）

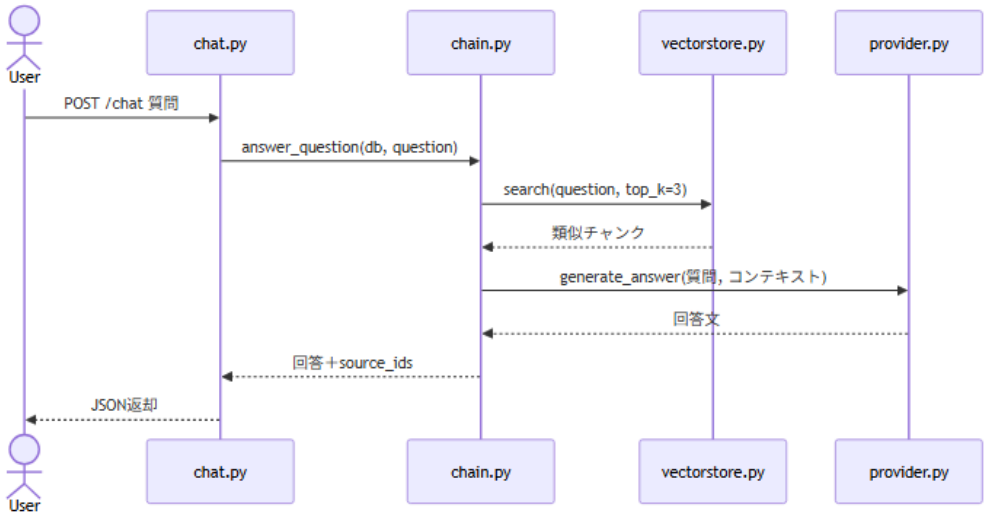



▶ 図の元データ（Mermaid）

RAG初心者向けの要点：

- **チャンク**：長文を500文字単位に切った断片です。検索精度とLLM入力長の調整役です。
- **Embedding**：文章を数値ベクトル化する処理です。意味の近さが数値の近さになります。
- **SQL検索との違い**：SQLは完全一致探し、ベクトル検索は意味の近さ探しです。「休暇は何日」と「年次休暇は10日」は文字は違いますが意味が近いため検索できます。

### 3.4 フェーズ3：質問応答（質問 → 回答）




▶ 図の元データ（Mermaid）

**データベースのテーブル構成：**

```
documents（文書本体）
  |
```

```
    └── document_chunks（RAG用断片）
        └── document_id で紐づく
        └── chunk_index、content、embeddingを保持
```

---

## 4. 中級者がつまずきやすいポイント

### 4.1 FastAPI編

**FastAPIの `Depends(get_db)`（documents.py:62）**

```python
def list_documents(db: Session = Depends(get_db)) -> list[Document]:
```

**何をしているのか**：「このAPIを呼ぶ前に `get_db()` を実行し、その結果を `db` 引数に入れてほしい」という宣言です。

**なぜ必要なのか**：DB接続の開閉を各APIに書くと重複します。`Depends` に任せると、成功時はセッション提供、終了時は自動closeになります。テスト時は `dependency_overrides` で偽DBに差し替えられます（ `tests/conftest.py` ）。

**間違えやすいポイント**：`Depends(get_db())` のように括弧付きで書くと実行結果が固定され、リクエストごとに新規接続されません。括弧なしが正解です。

**括弧付きで固定される理由**：`Depends` は呼出可能物（関数そのもの）を受け取り、要求のたびに呼び出す仕組みです。括弧付きは定義時（ `import` 時）に1回だけ `get_db()` が実行され、戻り値のgenerator objectが全要求で共有されます。1回目の終了時 `finally: db.close()` で閉じたSessionを使い回すため、2回目以降は接続切れや競合が起き、`dependency_overrides` による差替えもできません。括弧なしは要求のたびに `SessionLocal()` で新規生成と `close` が行われます。

---

**Pydanticの `from_attributes`（schemas/document.py）**

```python
class DocumentOut(BaseModel):
    model_config = {"from_attributes": True}
```

**何をしているのか**：SQLAlchemyの行オブジェクトからPydantic応答への変換を許可します。

**なぜ必要なのか**：`Document` 行を `DocumentOut` に変換する際、辞書でなく属性アクセス（ `doc.title` ）で読む必要があるためです。これがないと一覧・詳細APIの返却時に変換エラーになります。

---

**`on_event("startup")` の役割（main.py）**

起動時に `init_db()` を実行し、テーブルとpgvector拡張を作成します。テスト時はDB未起動でもimportできるよう、失敗時は警告記録のみにしています。

**注意点**：`on_event` は新版FastAPIで非推奨表示になりますが動作します。将来は `lifespan` 方式への置換対象です。

---

### 4.2 LangChain編

**TextSplitter — なぜ分割するのか（chunker.py）**

```python
splitter = RecursiveCharacterTextSplitter(chunk_size=500, chunk_overlap=50)
```

**何をしているのか**：長文を500文字単位に切り、50文字だけ重ねます。

**なぜ必要なのか**：区切れ目で文意が切断されるのを防ぐためです。重なり部分が前後関係を保持します。本実装ではLangChainがあればそれを使い、なければ単純分割に退避します。

**間違えやすいポイント**：`chunk_size` を大きくすれば精度が上がるわけではありません。大きすぎるとLLM入力が関連の薄い文章で埋まります。`config.py` の500と3件は学習用の出発点です。

---

**Embeddings — Fakeと本番の違い（embeddings.py:54）**

```
if settings.use_fake or not settings.openai_api_key:
    return [_fake_vector(t) for t in texts]
```

**何をしているのか**：既定は課金なしFake、本番のみOpenAI通信です。

**なぜ必要なのか**：学習中にAPI課金が発生しないようにするためです。Fakeは文字コード合計から決定的ベクトルを作るため、再実行しても同じ結果になります。

**間違えやすいポイント**：Fakeは意味を理解していません。文字の並びが近い文書が類似と判定されます。本番Embeddingに替えると意味検索になりますが、配線自体は同じです。

---

**RetrieverとChain — なぜ薄い層なのか（chain.py）**

```
hits = vectorstore.search(db, question)
context = "¥n".join(h.content for h in hits)
answer = generate_answer(question, context)
```

**何をしているのか**：検索と生成の順序だけを決めています。

**なぜ必要なのか**：LangChainの本格Chain（LCEL＝LangChain Expression Language等）に置き換える際、呼出側（`chat.py`）を変更せずに済むためです。現段階では見通し優先の最小実装です。

---

### 4.3 DB／RAG編

**pgvector拡張 — なぜ必要なのか（database.py）**

PostgreSQLでベクトル列を使うには `CREATE EXTENSION IF NOT EXISTS vector` が必要です。ローカル正規運用のSQLiteではJSON列で代替します（`models.py`）。件数が少ない学習段階ではPython側のコサイン計算で十分です。

**CREATE EXTENSIONの意味**：素のPostgreSQLに後付け機能を導入する命令であり、テーブル作成とは別物です。たとえるなら本体がスマホ、`EXTENSION` が追加アプリ、`CREATE` が導入実行です。`vector` はテーブル名ではなくpgvector拡張の名前であり、`IF NOT EXISTS` は導入済み時の重複誤差回避です。有効化すると `vector` 型と距離演算子とベクトル索引がそのDBで使えるようになり、`models.py:Vector(EMBEDDING_DIM)` の列定義が通ります。未実行だと `type "vector" does not exist` で起動しません。`docker-compose.yml:db image pgvector/pgvector:pg16` は機能ファイル入りを意味しますが、DB毎の有効化は別に必要であり、そのため `database.py:75` でPostgreSQL時のみ実行する2段階構成です。

---

**コサイン類似度 — 何を計算しているのか（vectorstore.py:28）**

```
dot / (na * nb)
```

**何をしているのか**：2ベクトルの向きの近さを0〜1で数値化しています。1に近いほど類似です。

**なぜ必要なのか**：ベクトル検索の核心だからです。質問ベクトルと全チャンクの類似度を計算し、上位3件（ `top_k` ）だけをLLMへ渡します。

**ユーザー視点の2ベクトル**：コード上の `a` は今の質問文1件（ `vectorstore.py:95 qvec = embed_query(question)` ）、 `b` は登録済み文書の各断片1件ずつ（ `r.embedding` ）です。たとえば登録「年次休暇は10日付与」に質問「休暇は何日」と送ると、両方の数値化結果の近さが採点され、上位3件が回答材料と `source_ids` （元文書番号）になります。Fake時は文字コード合計の偽数値のため文字面が近い断片が選ばれるだけであり、本番Embedding時は意味が近い断片が選ばれます。配線は同じです。

---

**`.env` と `.env.example` の違い**

| ファイル | 役割 | Git管理 |
|---|---|---|
| `.env` | 実設定値（APIキー含む） | 除外する |
| `.env.example` | 公開用見本（空欄） | 含める |

**間違えやすいポイント**： `.env` をcommitするとAPIキーが公開されます。 `config.py` は `.env` を読みますが、キーなしでもFake動作するため学習に支障はありません。

---

## 5. 操作と内部の対応（/docs利用者向け）

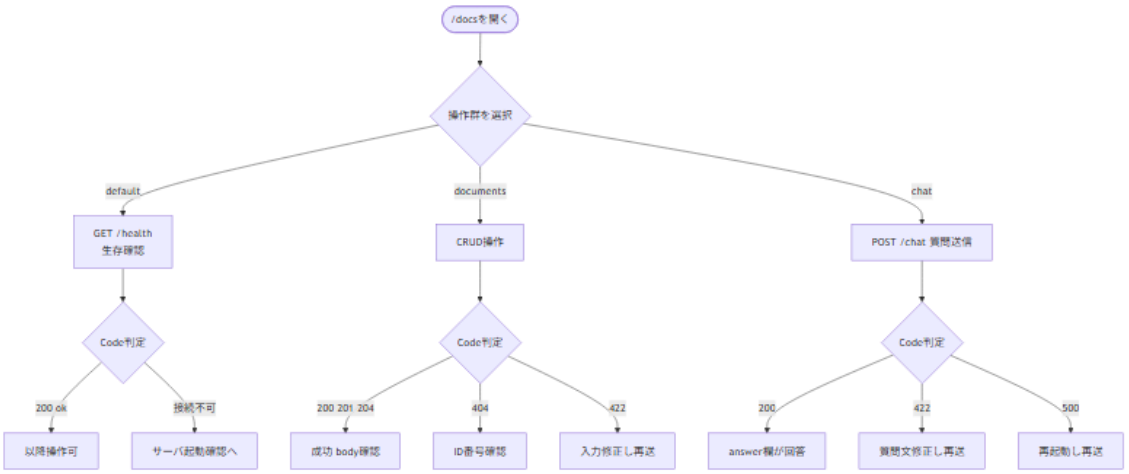
本章は操作画面（ `/docs` ）の表示と内部処理の対応を1か所にまとめたものです。たとえるなら、5.1は案内板の読み方、5.2は券売機の番号案内、5.3は厨房の手順書です。

### 5.1 /docsの4分類の読み方

| 分類 | 所属 | 役割 |
|---|---|---|
| default | GET /health | 生存確認です。タグなしのため未分類置場に表示されます |
| documents | 文書CRUD5件 | 登録・一覧・詳細・更新・削除です |
| chat | POST /chat | 質問応答です |
| schemas | 型定義 | 入出力雛形の参照用です。実行対象ではありません |

**注意点**： `/` は未定義のため404が正常です。確認は `/health` 、 `/docs` 、 `/documents` の3件で行います。

### 5.2 群別Code対応表




▶ 図の元データ（Mermaid）

**default群 GET /health**

| Code | 意味 | 対応 |
|---|---|---|
| 200 body ok | サーバ生存確定です | 以降操作可です |
| 接続自体不可 | サーバ未起動か別ポートです | 起動確認に戻ります |

default群にDELETEは存在しません。`/docs` に表示なしが正常です。

**documents群**

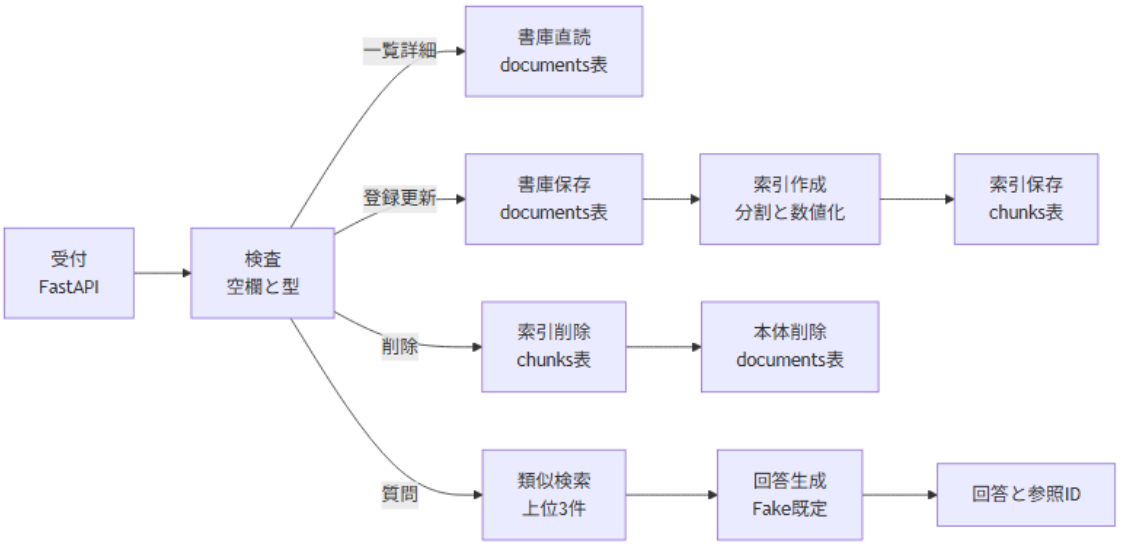
| 操作 | Code | 意味 | 対応 |
|---|---|---|---|
| GET /documents | 200 [] | 登録ゼロで正常です | 異常ではありません |
| GET /documents | 200 件数あり | 登録済み一覧です | body確認です |
| GET /documents/id | 200 | 詳細表示です | body確認です |
| GET /documents/id | 404 | 存在しないIDです | 番号確認です |
| GET /documents/id | 422 | ID欄に数字以外です | 数字に修正します |
| POST /documents | 201 | 登録成功です | 返却idを控えます |
| POST /documents | 422 | titleかcontentが空です | 両方記載し再送します |
| PUT /documents/id | 200 | 更新成功です | 関連検索情報も置換済みです |
| PUT /documents/id | 404 | 対象なしです | id確認です |
| PUT /documents/id | 422 | 入力規則違反です | 空欄修正です |
| DELETE /documents/id | 204 | 削除成功です | bodyなしが正常です |
| DELETE /documents/id | 404 | 対象なしです | id確認です |

**chat群 POST /chat**

| Code | 意味 | 対応 |
|---|---|---|
| 200 answerあり source_idsあり | 会話成立です | answer欄が回答、source_idsが根拠番号です |
| 200 answerあり source_ids空 | 根拠なし回答です | 先に文書登録します |
| 422 | question空です | 1文字以上記入し再送します |
| 500 | 内部障害です | 再起動し再送します。継続時は記録します |

**会話成立条件**：先にPOST /documentsで登録し、次にPOST /chatで質問します。逆順では根拠空になります。

### 5.3 内部trace（画面の裏側）




▶ 図の元データ（Mermaid）

- 受付はFastAPIが行います。接続は要求ごとに開閉します。
- 検査で空欄と型を確認します。違反は422で返します。
- 一覧と詳細は書庫直読みでRAG不使用です。
- 登録と更新は保存後に索引を作り直します。削除は索引削除が先です。
- 質問は類似検索の上位3件だけを回答生成に渡します。

### 5.4 回答と異常の見分け方

- 成功形は `answer` と `source_ids` を持ちます。Code 200で返ります。
- 失敗形は `detail` と `msg` を持ちます。Code 422等で返ります。
- `/docs` は両雛形を常時表示します。実結果のCodeで判別します。

## 付録：学習の順番

```
STEP 1: README.md                  → 目的と使い方を理解
STEP 2: config.py                  → 設定値を把握
STEP 3: src/db/models.py           → 2テーブルを把握
STEP 4: src/api/routers/documents.py → CRUDを読む
```

```
STEP 5: src/rag/chunker.py          → 分割を読む
STEP 6: src/rag/embeddings.py       → Fakeと本番の切替を読む
STEP 7: src/rag/vectorstore.py      → 保存と検索を読む
STEP 8: src/llm/provider.py         → 切替を読む
STEP 9: src/rag/chain.py            → 回答手順を読む
STEP 10: src/api/routers/chat.py    → 質問応答を読む
STEP 11: tests/                     → 検証内容を読む
STEP 12: diagrams/                  → 図で全体を復習
STEP 13: 本書5章                     → 操作と内部の対応を復習
```

---

> *このドキュメントは `README.md` 、`AGENTS.md` 、`config.py` および `src/` 、`tests/` の実コードを参照して作成されています。初版 `beginner_overview.md` の継承版（Rev.B）です。Rev.Aの別名保存内容を維持しています。*